BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

Đồ Án Môn Xử Lý Ảnh Và Ứng Dụng

ĐỀ TÀI ỨNG DỤNG MÔ HÌNH DUAL - STREAM VÀ CƠ CHẾ CHÚ Ý SONG SONG TRONG PHÁT HIỆN VIÊM PHỔI TRÊN ẢNH X - QUANG

Giảng viên hướng dẫn : ThS. Cáp Phạm Đình Thăng

Lớp: CS406.P11
Nhóm: UIT#4
Sinh viên thực hiện:
Mai Thái Bình – 23520158
Đặng Vân Duy – 23520361
Vũ Việt Hoàng – 23520548
Lê Ngọc Thành – 23521443

TP. HỒ CHÍ MINH, THÁNG 01 NĂM 2026

Chapter 1 – Giới thiệu **3**
Chapter 2 - Các nghiên cứu liên quan **4**
2.1 Phát hiện viêm phổi trên ảnh X-quang ngực **4**
2.2 Các phương pháp phát hiện viêm phổi dựa trên học sâu 4
2.2.1 Mô hình phát hiện đối tượng hai giai đoạn **4**
2.2.2 Mô hình phát hiện đối tượng một giai đoạn **4**
2.2.3 Các mô hình phát hiện không dùng anchor **4**
2.3 Hạn chế của các phương pháp hiện tại **5**
2.4 Động cơ đề xuất phương pháp **5**
Chapter 3 - Tổng quan đề tài **6**
3.1 Mô tả bài toán **6**
3.2 Mô tả tập dữ liệu **6**
3.2.1 RSNA Pneumonia Detection Challenge **6**
3.2.2 Bộ dữ liệu RSNA đã tiền xử lý (2023) **6**
3.3 Gán nhãn dữ liệu và định dạng **6**
3.4 Quy trình tổng thể của hệ thống **7**
Chapter 4 - Phương pháp đề xuất **8**
4.1 Tổng quan phương pháp đề xuất 8
4.2 Phương pháp baseline: Faster R-CNN với ResNet50-FPN 8
4.2.1 Kiến trúc mô hình 8
4.2.2 Tiền xử lý dữ liệu 8
4.2.3 Chiến lược huấn luyện 9
4.2.4 Chỉ số đánh giá 9
4.2.5 Phân tích hiệu năng mô hình baseline 9
4.3 Baseline tối ưu tốc độ: RetinaNet với ResNet50-FPN 9
4.3.1 Tổng quan RetinaNet 9
4.3.2 Lý do lựa chọn RetinaNet 10
4.3.3 Mạng backbone: ResNet50 10
4.3.4 Feature Pyramid Network (FPN) 11
4.3.5 Focal Loss cho bài toán mất cân bằng lớp 11
4.3.6 Huấn luyện và suy luận 12
4.3.7 Thảo luận 12
4.4 Baseline nâng cao: Mô hình phát hiện một giai đoạn không anchor với CNN và FPN 13
4.4.1 Động cơ của Anchor-Free Object Detection 13
4.4.2 Mô hình hóa bài toán phát hiện không anchor 13
4.4.3 Kiến trúc mạng: CNN Backbone with FPN 14
4.4.4 Anchor-Free Detection Head 14
4.4.5 Hàm mất mát và tối ưu hóa 15
4.4.6 Chiến lược huấn luyện 16
4.4.7 Thảo luận 16

4.5 Mô hình Dual-Stream PAFM..... 16
4.5.1 Động cơ của Dual-Stream PAFM.....16
4.5.2 Backbone Network.....17
4.5.3 Mô hình hợp nhất chú ý song song (PAFM)..... 18
4.5.4 Hàm mất mát và tối ưu hóa..... 19
4.5.5 Chiến lược huấn luyện.....19
4.5.6 Kết luận..... 20
Chapter 5: Thực nghiệm.....21
5.1 Các chỉ số đánh giá.....21
5.1.1 Chỉ số Giao trên Hợp (Intersection over Union - IoU)..... 21
5.1.2 Độ chính xác trung bình (Mean Average Precision - mAP).....21
a. Các ngưỡng đánh giá (Thresholds).....21
b. Công thức tính mAP.....21
5.1.3 Chỉ số F1 (F1 - Score).....22
5.2 Dataset.....22
5.2.1 Thu nhận tập dữ liệu: RSNA Pneumonia Processed Dataset.....22
5.2.2 Phân chia dữ liệu và cấu trúc thư mục..... 22
5.2.3 Đặc tả dữ liệu và nhãn chuẩn (Ground Truth).....24
5.2.4 Stochastic Data Augmentation and Preprocessing.....24
5.3 Thiết lập và môi trường thực nghiệm.....27
5.3.1 Khung Phần cứng và Phần mềm (Hardware and Software Framework) 27
5.3.2 Lựa chọn mô hình và kiến trúc backbone..... 28
5.3.3 Cấu hình huấn luyện và siêu tham số.....28
5.4 Kết quả Thực nghiệm và Phân tích..... 29
Chapter 6. Kết luận và hướng phát triển.....32
6.1 Tóm tắt kết quả đạt được.....32
6.2 Thảo luận và nhận xét..... 32
6.3 Hạn chế.....32
6.4 Hướng phát triển trong tương lai.....33
Chapter 7. Phụ lục.....33
7.1 Đóng góp công việc và phân công vai trò.....34
Tài liệu tham khảo.....35

Chapter 1 – Giới thiệu

Viêm phổi là một trong những nguyên nhân hàng đầu gây tử vong trên toàn cầu, đặc biệt ở trẻ em, người cao tuổi và các nhóm có hệ miễn dịch suy giảm. Theo Tổ chức Y tế Thế giới (WHO), viêm phổi chiếm tỷ lệ lớn trong các ca tử vong do bệnh lý hô hấp, đặt ra nhu cầu cấp thiết về các phương pháp chẩn đoán sớm, chính xác và có khả năng mở rộng trong thực tế lâm sàng. Trong bối cảnh đó, ảnh X-quang ngực (Chest X-ray) vẫn là phương tiện chẩn đoán hình ảnh phổ biến nhất nhờ chi phí thấp, thời gian chụp nhanh và khả năng triển khai rộng rãi tại nhiều cơ sở y tế.

Tuy nhiên, việc chẩn đoán viêm phổi từ ảnh X-quang đặt ra nhiều thách thức đáng kể. Các tổn thương phổi thường biểu hiện dưới dạng vùng mờ (lung opacity) với độ tương phản thấp, ranh giới không rõ ràng và dễ bị nhầm lẫn với cấu trúc giải phẫu bình thường như xương sườn, tim hoặc mô mềm. Ngoài ra, chất lượng ảnh không đồng nhất, sự khác biệt giữa các thiết bị chụp và yếu tố chủ quan từ bác sĩ đọc phim có thể dẫn đến sai lệch trong quá trình chẩn đoán, đặc biệt trong các tình huống quá tải bệnh nhân.

Sự phát triển mạnh mẽ của học sâu (Deep Learning), đặc biệt là các mô hình thị giác máy tính dựa trên mạng nơ-ron tích chập (Convolutional Neural Networks – CNNs), đã mở ra nhiều hướng tiếp cận mới cho bài toán phân tích ảnh y sinh. Trong những năm gần đây, nhiều hệ thống tự động đã được đề xuất nhằm hỗ trợ bác sĩ trong việc phát hiện và khoanh vùng tổn thương viêm phổi trên ảnh X-quang. Các mô hình phát hiện đối tượng (Object Detection) như Faster R-CNN, RetinaNet hay các phương pháp anchor-free cho thấy tiềm năng lớn trong việc xác định vị trí vùng bệnh thông qua bounding box, góp phần giảm tải công việc và nâng cao độ chính xác chẩn đoán.

Trong khuôn khổ học phần **Xử lý ảnh và Ứng dụng (CS406)**, nhóm chúng em tập trung xây dựng và đánh giá một hệ thống phát hiện viêm phổi tự động trên ảnh X-quang ngực, sử dụng **RSNA Pneumonia Detection Challenge (2018)** – một trong những bộ dữ liệu chuẩn và được sử dụng rộng rãi trong nghiên cứu học sâu y sinh. Phiên bản **RSNA Preprocessed Dataset (2023)** được lựa chọn nhằm đảm bảo tính nhất quán trong tiền xử lý và thuận lợi cho quá trình huấn luyện, đánh giá mô hình.

Mục tiêu chính của báo cáo này là:

- Trình bày bài toán phát hiện viêm phổi trên ảnh X-quang dưới góc nhìn xử lý ảnh và học sâu.
- Phân tích các phương pháp tiếp cận tiêu biểu, bao gồm các mô hình hai giai đoạn (two-stage), một giai đoạn (one-stage) và anchor-free.
- Đánh giá định lượng hiệu quả của các mô hình thông qua các thước đo chuẩn như ROC-AUC, F1-score và mAP.
- Thảo luận ưu điểm, hạn chế cũng như hướng phát triển trong tương lai của hệ thống.

Chapter 2 - Các nghiên cứu liên quan

2.1 Phát hiện viêm phổi trên ảnh X-quang ngực

Viêm phổi là một bệnh lý hô hấp nghiêm trọng, thường được chẩn đoán thông qua ảnh X-quang ngực (Chest X-ray – CXR) trong thực hành lâm sàng. Ảnh X-quang cho phép quan sát các bất thường trong nhu mô phổi, đặc biệt là các vùng mờ (lung opacity) – dấu hiệu đặc trưng của viêm phổi. Tuy nhiên, việc phát hiện các tổn thương này không hề đơn giản do đặc tính của ảnh X-quang: ảnh có độ tương phản thấp, nhiều nhiễu, và sự chồng lấp phức tạp của các cấu trúc giải phẫu như xương sườn, tim và mô mềm [1].

Truyền thống, quá trình chẩn đoán viêm phổi chủ yếu dựa vào kinh nghiệm và kỹ năng của bác sĩ chẩn đoán hình ảnh. Cách tiếp cận này tuy hiệu quả trong nhiều trường hợp, nhưng dễ chịu ảnh hưởng bởi yếu tố chủ quan và gặp hạn chế khi số lượng bệnh nhân tăng cao. Ngoài ra, sự khác biệt về chất lượng thiết bị chụp và điều kiện chụp giữa các cơ sở y tế cũng làm tăng nguy cơ sai sót trong chẩn đoán [2].

2.2 Các phương pháp phát hiện viêm phổi dựa trên học sâu

2.2.1 Mô hình phát hiện đối tượng hai giai đoạn

Các mô hình phát hiện đối tượng hai giai đoạn (two-stage detectors), tiêu biểu là Faster R-CNN, đã được áp dụng rộng rãi trong nhiều bài toán thị giác máy tính. Kiến trúc này sử dụng mạng đề xuất vùng (Region Proposal Network – RPN) để sinh ra các vùng ứng viên, sau đó thực hiện phân loại và hồi quy bounding box trong giai đoạn thứ hai [3].

Trong bài toán phát hiện viêm phổi trên ảnh X-quang, Faster R-CNN cho thấy khả năng định vị chính xác các vùng tổn thương nhờ cơ chế học đặc trưng sâu và phân cấp [4]. Tuy nhiên, do cấu trúc phức tạp và yêu cầu tính toán lớn, các mô hình two-stage thường có thời gian suy luận chậm, gây hạn chế trong các ứng dụng yêu cầu xử lý thời gian thực.

2.2.2 Mô hình phát hiện đối tượng một giai đoạn

Nhằm cải thiện tốc độ suy luận, các mô hình phát hiện một giai đoạn (one-stage detectors) như RetinaNet đã được đề xuất. RetinaNet sử dụng Feature Pyramid Network (FPN) để khai thác đặc trưng đa tỉ lệ và áp dụng hàm mất mát Focal Loss nhằm giải quyết vấn đề mất cân bằng dữ liệu giữa nền và đối tượng [5].

Trong bối cảnh phát hiện viêm phổi, nơi số lượng vùng không tổn thương chiếm đa số, Focal Loss giúp mô hình tập trung hơn vào các mẫu khó và cải thiện hiệu năng phát hiện các vùng mờ nhỏ [6]. Tuy nhiên, các mô hình one-stage vẫn gặp khó khăn trong việc định vị chính xác các tổn thương có hình dạng không rõ ràng và độ tương phản thấp.

2.2.3 Các mô hình phát hiện không dùng anchor

Các phương pháp phát hiện anchor-free được đề xuất nhằm loại bỏ sự phụ thuộc vào anchor box thiết kế thủ công. Thay vào đó, mô hình trực tiếp dự đoán tâm đối tượng và khoảng cách đến các cạnh bounding box, giúp đơn giản hóa kiến trúc và giảm số siêu tham số cần tinh chỉnh [7].

Đối với ảnh X-quang ngực, nơi tổn thương viêm phổi có hình dạng bất quy tắc và kích thước đa dạng, các mô hình anchor-free được xem là phù hợp hơn so với các phương pháp anchor-based truyền thống [8]. Dù vậy, hiệu quả của các phương pháp này vẫn bị ảnh hưởng bởi nhiễu ảnh và sự chồng lấp của các cấu trúc giải phẫu.

2.3 Hạn chế của các phương pháp hiện tại

Mặc dù đạt được nhiều kết quả tích cực, các phương pháp hiện tại vẫn tồn tại một số hạn chế đáng kể. Thứ nhất, hầu hết các mô hình chỉ dựa vào bounding box để mô tả vùng tổn thương, trong khi bounding box không phản ánh chính xác hình dạng thực tế của vùng viêm phổi [9].

Thứ hai, ảnh X-quang ngực có độ tương phản thấp và nhiều nhiễu, khiến mô hình dễ nhầm lẫn giữa tổn thương bệnh lý và các cấu trúc giải phẫu bình thường. Cuối cùng, sự mất cân bằng dữ liệu giữa các lớp vẫn là một thách thức lớn, ảnh hưởng trực tiếp đến khả năng tổng quát hóa của mô hình [10].

2.4 Động cơ đề xuất phương pháp

Những hạn chế trên cho thấy nhu cầu về các phương pháp phát hiện viêm phổi hiệu quả hơn, có khả năng khai thác đặc trưng ảnh tốt hơn và cải thiện độ chính xác định vị vùng tổn thương. Dựa trên các quan sát này, nhóm chúng em đề xuất một hướng tiếp cận cải tiến, được trình bày chi tiết trong **Chương 4**.

Chapter 3 - Tổng quan đề tài

3.1 Mô tả bài toán

Trong đồ án này, nhóm chúng em tập trung vào bài toán **phát hiện viêm phổi (Pneumonia Detection)** trên ảnh X-quang ngực (Chest X-ray). Cụ thể, bài toán được mô hình hóa dưới dạng **phát hiện đối tượng (Object Detection)**, trong đó mục tiêu là xác định **vị trí** của các vùng tổn thương viêm phổi thông qua các bounding box trên ảnh đầu vào.

Khác với bài toán phân loại ảnh (image classification) chỉ trả lời câu hỏi ảnh có viêm phổi hay không, bài toán phát hiện đối tượng yêu cầu mô hình không chỉ nhận diện sự tồn tại của tổn thương mà còn phải **định vị chính xác vùng bất thường** trong phổi. Điều này mang ý nghĩa thực tiễn cao trong hỗ trợ bác sĩ chẩn đoán, giúp trực quan hóa khu vực nghi ngờ và giảm nguy cơ bỏ sót tổn thương.

Về mặt đầu vào – đầu ra, bài toán được mô tả như sau:

> **Đầu vào**: Ảnh X-quang ngực đơn kênh (grayscale).
> **Đầu ra**: Một hoặc nhiều bounding box biểu diễn vị trí vùng viêm phổi, kèm theo độ tin cậy (confidence score).

3.2 Mô tả tập dữ liệu

3.2.1 RSNA Pneumonia Detection Challenge

Nguồn dữ liệu được sử dụng trong đồ án là **RSNA Pneumonia Detection Challenge (2018)** – một bộ dữ liệu chuẩn được công bố bởi Hiệp hội X-quang Bắc Mỹ (Radiological Society of North America – RSNA). Bộ dữ liệu này được xây dựng nhằm thúc đẩy nghiên cứu các phương pháp tự động phát hiện viêm phổi từ ảnh X-quang ngực, và đã được sử dụng rộng rãi trong nhiều công trình nghiên cứu học sâu y sinh.

Mỗi ảnh trong dataset được gán nhãn bởi các chuyên gia chẩn đoán hình ảnh, trong đó các vùng viêm phổi (nếu có) được đánh dấu bằng bounding box. Điều này cho phép tiếp cận bài toán dưới dạng phát hiện đối tượng thay vì chỉ phân loại.

3.2.2 Bộ dữ liệu RSNA đã tiền xử lý (2023)

Trong đồ án này, nhóm sử dụng **RSNA Preprocessed Dataset (2023)** – phiên bản đã được tiền xử lý từ bộ dữ liệu gốc RSNA 2018. Việc sử dụng phiên bản tiền xử lý giúp:

- Đảm bảo tính nhất quán về kích thước ảnh và định dạng dữ liệu.
- Giảm thiểu sai khác do các bước tiền xử lý thủ công.
- Thuận tiện cho quá trình huấn luyện và so sánh các mô hình.

Dataset sau tiền xử lý vẫn giữ nguyên bản chất bài toán và thông tin nhãn bounding box, đảm bảo tính phù hợp cho việc đánh giá các mô hình phát hiện viêm phổi.

> **Lưu ý:** Đồ án **chỉ sử dụng duy nhất** bộ dữ liệu RSNA Preprocessed Dataset (2023), không kết hợp thêm bất kỳ nguồn dữ liệu nào khác.

3.3 Gán nhãn dữ liệu và định dạng

Mỗi mẫu dữ liệu trong tập huấn luyện bao gồm:

- Ảnh X-quang ngực.
- Thông tin nhãn tương ứng, bao gồm:
    - Tọa độ bounding box (x, y, width, height).
    - Nhãn lớp (pneumonia hoặc background).

Đối với các ảnh không chứa tổn thương viêm phổi, nhãn được gán là background, đóng vai trò quan trọng trong việc huấn luyện mô hình phân biệt giữa vùng bệnh lý và vùng bình thường.
Định dạng nhãn được chuẩn hóa để tương thích với các mô hình phát hiện đối tượng phổ biến, tạo điều kiện thuận lợi cho quá trình huấn luyện và đánh giá.

3.4 Quy trình tổng thể của hệ thống

Quy trình tổng thể của hệ thống phát hiện viêm phổi trong đồ án được minh họa trong **Hình 3.1**. Pipeline bao gồm các bước chính sau:

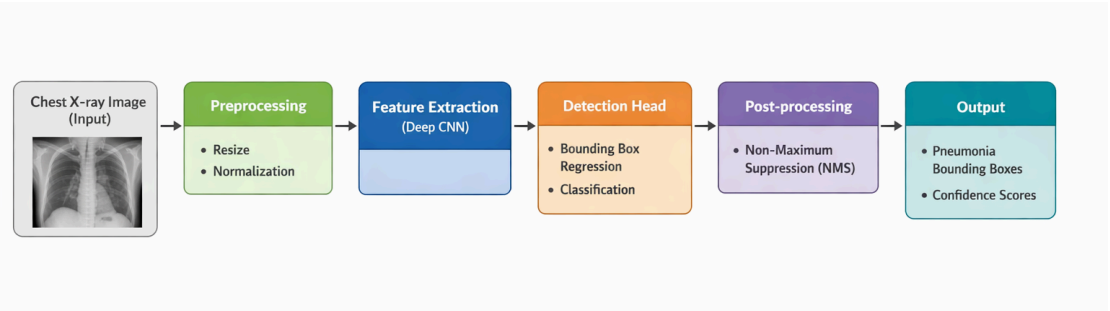

Input Image: Ảnh X-quang ngực được đưa vào hệ thống.
Preprocessing: Ảnh được chuẩn hóa kích thước, cường độ điểm ảnh và các bước tiền xử lý cần thiết.
Feature Extraction: Mô hình học sâu trích xuất đặc trưng từ ảnh đầu vào.
Detection Head: Dự đoán bounding box và độ tin cậy cho các vùng nghi ngờ viêm phổi.
Post-processing: Áp dụng các kỹ thuật như Non-Maximum Suppression (NMS) để loại bỏ các bounding box trùng lặp.

Chapter 4 - Phương pháp đề xuất

4.1 Tổng quan phương pháp đề xuất

Trong chương này, chúng em trình bày phương pháp được sử dụng để phát hiện viêm phổi trên ảnh X-quang ngực, dựa trên bài toán phát hiện đối tượng (object detection). Phương pháp đề xuất được xây dựng nhằm tận dụng khả năng học đặc trưng mạnh mẽ của các mô hình học sâu, đồng thời khắc phục những hạn chế đã được phân tích trong Chương 2.

Hệ thống tổng thể tuân theo pipeline đã được mô tả trong Chương 3, bao gồm các bước: tiền xử lý ảnh, trích xuất đặc trưng, dự đoán bounding box và hậu xử lý kết quả. Trọng tâm của chương này là mô tả chi tiết kiến trúc mô hình và các thành phần chính trong quá trình huấn luyện và suy luận.

4.2 Phương pháp baseline: Faster R-CNN với ResNet50-FPN

4.2.1 Kiến trúc mô hình

Trong đồ án này, nhóm sử dụng **Faster R-CNN với backbone ResNet50 kết hợp Feature Pyramid Network (FPN)** làm mô hình baseline cho bài toán phát hiện viêm phổi trên ảnh X-quang ngực. Faster R-CNN là một mô hình phát hiện đối tượng hai giai đoạn (two-stage object detector), bao gồm hai thành phần chính: mạng đề xuất vùng (Region Proposal Network – RPN) và đầu phát hiện (Detection Head).

Backbone **ResNet50** được lựa chọn nhằm trích xuất các đặc trưng sâu từ ảnh đầu vào. Nhờ cơ chế residual connection, ResNet50 cho phép xây dựng mạng đủ sâu để học các đặc trưng phức tạp mà vẫn đảm bảo khả năng hội tụ ổn định. Trên backbone này, **Feature Pyramid Network (FPN)** được tích hợp để khai thác đặc trưng đa tỉ lệ, giúp mô hình phát hiện hiệu quả các vùng tổn thương viêm phổi có kích thước và hình dạng khác nhau.

Kiến trúc Faster R-CNN với ResNet50-FPN được đánh giá là phù hợp để làm baseline nhờ độ ổn định cao và hiệu năng tốt trong nhiều bài toán phát hiện đối tượng, đặc biệt trong lĩnh vực ảnh y sinh.

4.2.2 Tiền xử lý dữ liệu

Mô hình baseline được huấn luyện và đánh giá trên **RSNA Preprocessed Dataset (2023)**, một phiên bản tiền xử lý từ bộ dữ liệu RSNA Pneumonia Detection Challenge (2018). Mỗi mẫu dữ liệu bao gồm ảnh X-quang ngực và các nhãn bounding box tương ứng với vùng tổn thương viêm phổi.

Trong quá trình tiền xử lý, ảnh đầu vào được chuẩn hóa về kích thước và giá trị điểm ảnh nhằm đảm bảo tính nhất quán khi đưa vào mô hình. Các thông tin nhãn bounding box được chuyển đổi về định dạng phù hợp với mô hình Faster R-CNN.

4.2.3 Chiến lược huấn luyện

Mô hình Faster R-CNN được huấn luyện theo chiến lược huấn luyện end-to-end trên tập huấn luyện của dataset. Quá trình huấn luyện được thực hiện theo mini-batch, trong đó các tham số của backbone, RPN và Detection Head được tối ưu đồng thời.

Hàm mất mát tổng hợp của Faster R-CNN bao gồm:

- Hàm mất mát phân loại cho RPN và Detection Head.
- Hàm mất mát hồi quy bounding box nhằm cải thiện độ chính xác định vị vùng tổn thương.

Trong quá trình huấn luyện, mô hình được theo dõi hiệu năng trên tập validation để đánh giá khả năng tổng quát hóa và tránh hiện tượng overfitting. Việc huấn luyện được dừng khi mô hình đạt hiệu năng ổn định theo tiêu chí đánh giá đã chọn.

4.2.4 Chỉ số đánh giá

Để đánh giá hiệu năng của mô hình baseline, nhóm sử dụng chỉ số **mean Average Precision tại ngưỡng IoU = 0.5 (mAP@0.5)**. Đây là một thước đo phổ biến trong bài toán phát hiện đối tượng, phản ánh đồng thời khả năng phân loại và định vị bounding box.

Chỉ số mAP@0.5 đặc biệt phù hợp với bài toán phát hiện viêm phổi, trong đó việc xác định đúng vị trí vùng tổn thương có ý nghĩa quan trọng trong hỗ trợ chẩn đoán lâm sàng.

4.2.5 Phân tích hiệu năng mô hình baseline

Faster R-CNN với ResNet50-FPN cho thấy hiệu năng phát hiện ổn định và khả năng định vị chính xác các vùng tổn thương viêm phổi. Nhờ kiến trúc two-stage và đặc trưng đa tỉ lệ từ FPN, mô hình đạt độ chính xác cao trong việc phát hiện các vùng mờ có kích thước khác nhau trên ảnh X-quang.

Tuy nhiên, do cấu trúc phức tạp và yêu cầu tính toán lớn, Faster R-CNN có **thời gian suy luận tương đối chậm**, gây hạn chế khi triển khai trong các hệ thống yêu cầu tốc độ xử lý cao. Hạn chế này là động lực để nhóm tiếp tục nghiên cứu và đánh giá các mô hình one-stage detector, trong đó **RetinaNet** được lựa chọn nhằm tối ưu hóa tốc độ mà vẫn duy trì hiệu năng phát hiện ở mức chấp nhận được.

4.3 Baseline tối ưu tốc độ: RetinaNet với ResNet50-FPN

4.3.1 Tổng quan RetinaNet

RetinaNet là một mô hình phát hiện đối tượng **một giai đoạn (one-stage object detector)**, trong đó việc dự đoán nhãn lớp và tọa độ bounding box được thực hiện

trực tiếp trên các feature maps trích xuất từ ảnh đầu vào, **không thông qua bước đề xuất vùng trung gian** như trong các mô hình hai giai đoạn (ví dụ Faster R-CNN).

Khác với các one-stage detector truyền thống thường gặp vấn đề suy giảm độ chính xác, RetinaNet được thiết kế nhằm khắc phục hạn chế này thông qua việc kết hợp kiến trúc **Feature Pyramid Network (FPN)** và hàm mất mát **Focal Loss**, cho phép mô hình đạt được sự cân bằng tốt giữa tốc độ suy luận và hiệu năng phát hiện.

4.3.2 Lý do lựa chọn RetinaNet

Việc lựa chọn RetinaNet trong đồ án này xuất phát từ ba động cơ chính.

Thứ nhất, RetinaNet có **tốc độ suy luận nhanh hơn** so với các mô hình two-stage như Faster R-CNN do loại bỏ hoàn toàn bước Region Proposal Network (RPN). Điều này giúp giảm độ phức tạp của pipeline và phù hợp hơn với các kịch bản yêu cầu xử lý nhanh hoặc thử nghiệm trên tập dữ liệu lớn.

Thứ hai, bài toán phát hiện viêm phổi trên ảnh X-quang có đặc trưng **mất cân bằng dữ liệu nghiêm trọng**, trong đó số lượng vùng nền (background) chiếm ưu thế lớn so với số vùng tổn thương thực sự. RetinaNet được thiết kế đặc biệt để xử lý vấn đề này thông qua Focal Loss, giúp mô hình tập trung hơn vào các mẫu khó và hiếm.

Thứ ba, RetinaNet là một **baseline phổ biến và được chấp nhận rộng rãi** trong cộng đồng nghiên cứu thị giác máy tính và ảnh y sinh, cho phép so sánh kết quả của nhóm với các công trình liên quan một cách công bằng và có cơ sở.

4.3.3 Mạng backbone: ResNet50

Trong kiến trúc RetinaNet, **ResNet50** được sử dụng làm backbone cho quá trình trích xuất đặc trưng. ResNet50 là một mạng nơ-ron tích chập sâu với cơ chế **residual connection**, cho phép học các biểu diễn đặc trưng phức tạp mà vẫn đảm bảo quá trình lan truyền gradient ổn định.

Việc lựa chọn ResNet50 thay vì các backbone sâu hơn như ResNet101 hay ResNet152 nhằm đạt được sự cân bằng giữa:

- Khả năng trích xuất đặc trưng.
- Chi phí tính toán.
- Nguy cơ overfitting trên dữ liệu ảnh X-quang.

Đối với ảnh X-quang ngực, vốn có cấu trúc tương đối đơn giản và ít màu sắc, ResNet50 được đánh giá là đủ mạnh để học các đặc trưng cần thiết mà không làm tăng đáng kể độ phức tạp của mô hình.

4.3.4 Feature Pyramid Network (FPN)

Một trong những thách thức lớn trong bài toán phát hiện viêm phổi là **kích thước và hình dạng của vùng tổn thương thay đổi đáng kể** giữa các ảnh. Các tổn thương có thể xuất hiện dưới dạng các vùng mờ nhỏ hoặc lan rộng trên một phần lớn phổi.

Để giải quyết vấn đề này, RetinaNet tích hợp **Feature Pyramid Network (FPN)** nhằm khai thác thông tin đa tỉ lệ từ backbone. FPN kết hợp các feature maps ở nhiều mức độ khác nhau, cho phép mô hình đồng thời tận dụng:

- Thông tin ngữ nghĩa cấp cao từ các tầng sâu.
- Thông tin không gian chi tiết từ các tầng nông.

Nhờ đó, mô hình có khả năng phát hiện hiệu quả cả các tổn thương nhỏ lẫn các vùng viêm phổi có kích thước lớn trên ảnh X-quang.

4.3.5 Focal Loss cho bài toán mất cân bằng lớp

Hàm mất mát đóng vai trò quan trọng trong hiệu năng của RetinaNet. Trong các bài toán phát hiện đối tượng truyền thống, hàm mất mát Cross-Entropy thường gặp khó khăn khi dữ liệu bị mất cân bằng nghiêm trọng, do các mẫu dễ (background) chiếm ưu thế trong quá trình huấn luyện.

Để khắc phục vấn đề này, RetinaNet sử dụng **Focal Loss**, được định nghĩa như sau:

$$FL(p_t) = -\alpha(1 - p_t)^{\gamma} \log(p_t)$$

trong đó:

- pt là xác suất dự đoán cho lớp đúng,
- α là hệ số cân bằng giữa các lớp,
- γ là tham số điều chỉnh mức độ tập trung vào các mẫu khó.

Focal Loss làm giảm đóng góp của các mẫu dễ vào hàm mất mát, đồng thời tăng trọng số cho các mẫu khó, từ đó giúp mô hình học tốt hơn các vùng tổn thương viêm phổi hiếm gặp trên ảnh X-quang.

4.3.6 Huấn luyện và suy luận

Trong quá trình triển khai, mô hình RetinaNet với ResNet50-FPN được huấn luyện theo cách end-to-end trên tập huấn luyện của RSNA Preprocessed Dataset (2023). Việc khởi tạo mô hình được thực hiện thông qua các trọng số pretrained, giúp cải thiện tốc độ hội tụ và độ ổn định trong quá trình huấn luyện.

Ví dụ khởi tạo mô hình trong thực nghiệm:

```
from torchvision.models.detection import retinanet_resnet50_fpn
model = retinanet_resnet50_fpn(pretrained=True)
```

Trong quá trình huấn luyện, tổng hàm mất mát được tính bằng cách cộng các thành phần mất mát do mô hình trả về:

```
loss_dict = model(images, targets)
loss = sum(loss for loss in loss_dict.values())
```

Cách huấn luyện này cho phép tối ưu đồng thời các tham số của backbone, FPN và các head dự đoán.

4.3.7 Thảo luận

So với Faster R-CNN, RetinaNet cho thấy **ưu thế rõ rệt về tốc độ suy luận** nhờ kiến trúc one-stage và pipeline gọn nhẹ hơn. Tuy nhiên, trong một số trường hợp, đặc biệt khi vùng tổn thương có hình dạng phức tạp hoặc ranh giới không rõ ràng, hiệu năng định vị của RetinaNet có thể kém hơn so với các mô hình two-stage.

Những hạn chế này là động lực để nhóm tiếp tục nghiên cứu các phương pháp phát hiện nâng cao hơn, bao gồm các mô hình **anchor-free** và kiến trúc **Dual-Stream kết hợp Attention**, nhằm cải thiện khả năng khai thác đặc trưng và nâng cao độ chính xác phát hiện viêm phổi.

4.4 Baseline nâng cao: Mô hình phát hiện một giai đoạn không anchor với CNN và FPN

4.4.1 Động cơ của Anchor-Free Object Detection

Các phương pháp phát hiện đối tượng dựa trên anchor (anchor-based), tiêu biểu như Faster R-CNN và RetinaNet, yêu cầu xác định trước tập anchor box với nhiều tỉ lệ và tỷ lệ khung hình khác nhau. Tuy nhiên, trong bài toán phát hiện viêm phổi trên ảnh X-quang ngực, cách tiếp cận này bộc lộ một số hạn chế đáng kể.

Thứ nhất, các vùng tổn thương viêm phổi thường có **hình dạng không đều, biên mờ và kích thước thay đổi lớn**, khiến việc thiết kế anchor box phù hợp trở nên khó khăn và mang tính kinh nghiệm. Thứ hai, việc sử dụng anchor làm gia tăng số lượng siêu tham số cần tinh chỉnh, từ đó làm phức tạp quá trình huấn luyện và giảm khả năng tổng quát hóa.

Do đó, trong mục này, nhóm khảo sát một hướng tiếp cận nâng cao hơn bằng cách **loại bỏ hoàn toàn anchor**, chuyển sang mô hình **anchor-free one-stage detector**, trong đó bài toán phát hiện đối tượng được tái định nghĩa theo hướng dự đoán trực tiếp từ các đặc trưng không gian.

4.4.2 Mô hình hóa bài toán phát hiện không anchor

Trong mô hình anchor-free, mỗi điểm trên feature map được xem là một ứng viên tiềm năng cho tâm của đối tượng. Thay vì hồi quy từ anchor box, mô hình dự đoán trực tiếp khoảng cách từ điểm đó đến bốn biên của bounding box.

Cụ thể, với mỗi vị trí (i,j) trên feature map, bounding box được biểu diễn bởi vector:

$$bij=(lij,tij,rij,bij)$$

trong đó:

- lij: khoảng cách từ điểm (i,j) đến biên trái,
- tij: khoảng cách đến biên trên,
- rij: khoảng cách đến biên phải,
- bij: khoảng cách đến biên dưới của bounding box.

Song song với nhánh hồi quy bounding box, mô hình dự đoán xác suất tồn tại đối tượng tại vị trí đó thông qua nhánh phân loại:

$$p_{ij} = \sigma(f_{cls}(F_{ij}))$$

với Fij là vector đặc trưng tại vị trí (i,j) trên feature map và σ là hàm sigmoid.

Cách biểu diễn này cho phép mô hình thực hiện **dense prediction** một cách hoàn toàn tích chập (fully convolutional), không phụ thuộc vào kích thước ảnh đầu vào.

4.4.3 Kiến trúc mạng: CNN Backbone with FPN

Kiến trúc tổng thể của mô hình anchor-free trong nghiên cứu này bao gồm ba thành phần chính:

1. CNN backbone để trích xuất đặc trưng.
2. Feature Pyramid Network (FPN) để xử lý đặc trưng đa tỉ lệ.
3. Anchor-free detection head cho phân loại và hồi quy bounding box.

Giả sử feature map đầu ra từ backbone có dạng:

$$F \in \mathbb{R}^{C \times H \times W}$$

FPN kết hợp các feature maps ở nhiều mức độ khác nhau, tạo ra tập đặc trưng đa tỉ lệ {P3,P4,P5,… } Mỗi tầng FPN chịu trách nhiệm phát hiện các đối tượng trong một dải kích thước nhất định, được xác định bởi:

$$\text{level}(b) = \left\lfloor \log_2 \left(\frac{\sqrt{wh}}{s_0} \right) \right\rfloor$$

trong đó w và h là chiều rộng và chiều cao của bounding box, còn s0 là hệ số chuẩn hóa.

Việc sử dụng FPN trong anchor-free detection đóng vai trò đặc biệt quan trọng, bởi trong trường hợp không có anchor, mô hình phải dựa hoàn toàn vào đặc trưng đa tỉ lệ để nhận diện chính xác các vùng tổn thương với kích thước khác nhau.

4.4.4 Anchor-Free Detection Head

Trên mỗi tầng của FPN, một detection head chung được áp dụng để dự đoán phân loại và hồi quy bounding box. Detection head này bao gồm hai nhánh song song:

- Nhánh phân loại (classification head).
- Nhánh hồi quy (regression head).

Một cách biểu diễn đơn giản của detection head trong thực nghiệm được thể hiện như sau:

```
class AnchorFreeHead(nn.Module):
    def __init__(self, in_channels):
```

```
        super().__init__()
        self.cls_head = nn.Conv2d(in_channels, 1, kernel_size=3, padding=1)
        self.reg_head = nn.Conv2d(in_channels, 4, kernel_size=3, padding=1)

    def forward(self, x):
        cls_score = torch.sigmoid(self.cls_head(x))
        bbox_reg  = self.reg_head(x)
        return cls_score, bbox_reg
```

Cấu trúc này cho phép mô hình dự đoán trực tiếp:

- Xác suất tồn tại đối tượng tại mỗi vị trí.
- Khoảng cách đến các biên bounding box tương ứng.

4.4.5 Hàm mất mát và tối ưu hóa

Hàm mất mát tổng thể của mô hình được xây dựng từ hai thành phần chính: mất mát phân loại và mất mát hồi quy bounding box.

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda \mathcal{L}_{reg}$$

Trong đó:

- Lcls thường được cài đặt dưới dạng Focal Loss để xử lý mất cân bằng dữ liệu.
- Lreg là hàm mất mát dựa trên IoU (Intersection over Union) hoặc L1 loss.
- λ là hệ số cân bằng giữa hai thành phần.

Biểu diễn huấn luyện trong thực nghiệm:

```
loss_cls = focal_loss(pred_cls, gt_cls)
loss_reg = iou_loss(pred_reg, gt_reg)
loss = loss_cls + lambda_reg * loss_reg
```

Cách tối ưu này giúp mô hình học đồng thời vị trí và mức độ tin cậy của các vùng tổn thương viêm phổi.

4.4.6 Chiến lược huấn luyện

Mô hình anchor-free được huấn luyện theo cách end-to-end trên tập huấn luyện của RSNA Preprocessed Dataset (2023). Do không sử dụng anchor, quá trình huấn luyện:

- Giảm đáng kể số lượng siêu tham số cần tinh chỉnh.
- Đơn giản hóa pipeline huấn luyện so với các phương pháp anchor-based.

Mỗi feature map từ FPN được xử lý độc lập nhưng chia sẻ cùng detection head, giúp mô hình duy trì tính nhất quán trong quá trình học đặc trưng.

4.4.7 Thảo luận

So với RetinaNet, mô hình anchor-free one-stage detector mang lại một cách tiếp cận linh hoạt hơn khi xử lý các vùng tổn thương có hình dạng bất quy tắc và ranh giới không rõ ràng trên ảnh X-quang. Việc loại bỏ anchor giúp giảm sự phụ thuộc vào các giả định hình học thủ công và đơn giản hóa thiết kế mô hình.

Tuy nhiên, do mỗi điểm trên feature map đều được xem là một ứng viên, mô hình anchor-free có thể nhạy cảm hơn với nhiễu và phụ thuộc mạnh vào chất lượng đặc trưng trích xuất từ backbone và FPN. Những hạn chế này cho thấy cần có các cơ chế nâng cao khả năng khai thác thông tin ngữ cảnh và mối quan hệ không gian, từ đó tạo động lực cho việc đề xuất kiến trúc **Dual-Stream kết hợp Attention** trong phần tiếp theo.

4.5 Mô hình Dual-Stream PAFM

4.5.1 Động cơ của Dual-Stream PAFM

Các mô hình phát hiện đối tượng truyền thống như Faster R-CNN thường gặp khó khăn khi xử lý ảnh X-quang phổi do các vùng tổn thương thường có biên mờ và độ tương phản thấp. Việc chỉ dựa vào một luồng xử lý ảnh đơn lẻ (single-stream) dễ dẫn đến việc bỏ sót các đặc trưng quan trọng hoặc nhầm lẫn với nhiễu nền.

Để khắc phục, chúng tôi đề xuất kiến trúc Dual-Stream Faster R-CNN tích hợp Parallel Attention Fusion Module (PAFM). Thay vì thay đổi cơ chế anchor, phương pháp này tập trung nâng cao chất lượng đặc trưng đầu vào bằng cách xử lý song song hai luồng dữ liệu: ảnh gốc và ảnh tăng cường tương phản. Cơ chế Parallel Attention đóng vai trò cầu nối, giúp mạng nơ-ron tự động "chú ý" và chắt lọc những đặc trưng

tinh tế nhất từ cả hai luồng, từ đó định vị chính xác vùng bệnh mà các mô hình đơn lẻ thường bỏ qua.

4.5.2 Backbone Network

Hệ thống sử dụng kiến trúc Dual-Stream Backbone dựa trên nền tảng ResNet-50 kết hợp với Feature Pyramid Network (FPN).

- Cấu trúc Dual-Stream: Backbone không xử lý một ảnh duy nhất mà nhận vào một tensor 6 kênh (được ghép từ 2 ảnh đầu vào khác nhau: s1_pixel và s2_pixel).
    - Stream 1: Xử lý ảnh gốc đã chuẩn hóa, giữ lại thông tin không gian trung thực.
    - Stream 2: Xử lý ảnh đã qua RandomEqualize (cân bằng lược đồ xám), giúp làm nổi bật các vùng mờ đục khó thấy.

```python
def get_transforms():
    train_geo = T.Compose([
        T.Resize((Config.IMG_SIZE, Config.IMG_SIZE), antialias=True),
        T.RandomHorizontalFlip(p=0.5),
        T.RandomAffine(degrees=10, translate=(0.15, 0.15), scale=(0.9, 1.1)),
        T.ClampBoundingBoxes()
    ])

    val_geo = T.Compose([
        T.Resize((Config.IMG_SIZE, Config.IMG_SIZE), antialias=True),
        T.ClampBoundingBoxes()
    ])

    s1_pixel = T.Compose([
        T.ColorJitter(brightness=0.15, contrast=0.15),
        T.ToDtype(torch.float32, scale=True),
        T.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
    ])

    s2_pixel = T.Compose([
        T.RandomEqualize(p=1.0),
        T.ToDtype(torch.float32, scale=True),
        T.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
    ])

    return (train_geo, s1_pixel, s2_pixel), (val_geo, s1_pixel, s2_pixel)
```

Hình 4.5.1: Mô tả chi tiết về các transform được sử dụng

- Siamese Architecture: Hai luồng này chia sẻ cùng một kiến trúc ResNet (conv1 đến layer4) để trích xuất đặc trưng phân cấp từ thấp đến cao (low-level đến semantic-level).
- FPN Integration: Sau khi các đặc trưng từ hai luồng được hợp nhất, chúng được đưa qua mạng FPN để tạo ra các bản đồ đặc trưng đa tỷ lệ (feat0, feat1, feat2, feat3), giúp mô hình phát hiện tốt cả các vùng viêm phổi nhỏ và lớn.

4.5.3 Mô hình hợp nhất chú ý song song (PAFM)

Điểm cải tiến cốt lõi của mô hình nằm ở module hợp nhất đặc trưng ParallelFusionModule. Thay vì chỉ cộng hoặc nối (concatenate) đơn thuần, chúng tôi sử dụng cơ chế Cross-Attention.

- Cơ chế hoạt động:Module này bao gồm lớp ParallelAttention thực hiện tính toán sự tương quan giữa hai luồng đặc trưng (s_1 và s_2):

$$Attention(Q,\ K,\ V)\ =\ softmax(\frac{QK^T}{\sqrt{d_k}})V$$

  Trong đó, đặc trưng của luồng này đóng vai trò là Query (Q), và đặc trưng của luồng kia đóng vai trò là Key (K) và Value (V). Điều này cho phép Stream 1 "mượn" thông tin ngữ cảnh từ Stream 2 và ngược lại.

```python
class ParallelAttention(nn.Module):
    def __init__(self, dim, num_heads=4, dropout_rate=0.1):
        super().__init__()
        self.num_heads = num_heads
        self.head_dim = dim // num_heads
        self.scale = self.head_dim ** -0.5

        self.to_q = nn.Linear(dim, dim, bias=False)
        self.to_k = nn.Linear(dim, dim, bias=False)
        self.to_v = nn.Linear(dim, dim, bias=False)
        self.proj = nn.Linear(dim, dim)
        self.dropout = nn.Dropout(dropout_rate)

    def forward(self, x_query, x_key):
        B, C, H, W = x_query.shape
        q = x_query.flatten(2).transpose(1, 2)
        k = x_key.flatten(2).transpose(1, 2)
        v = x_key.flatten(2).transpose(1, 2)

        q = self.to_q(q).reshape(B, H*W, self.num_heads, self.head_dim).permute(0, 2, 1, 3)
        k = self.to_k(k).reshape(B, H*W, self.num_heads, self.head_dim).permute(0, 2, 1, 3)
        v = self.to_v(v).reshape(B, H*W, self.num_heads, self.head_dim).permute(0, 2, 1, 3)

        attn = (q @ k.transpose(-2, -1)) * self.scale
        attn = attn.float().softmax(dim=-1).to(q.dtype)
        attn = self.dropout(attn)

        out = attn @ v
        out = out.transpose(1, 2).reshape(B, H*W, C)
        out = self.proj(out)
        return out.transpose(1, 2).reshape(B, C, H, W)
```

Hình 4.5.2: Khối Parallel Attention

- Xử lý ổn định số học: Tối ưu hóa bằng cách ép kiểu về float32 trước khi tính Softmax (attn.float().softmax(dim=-1)) để tránh lỗi NaN thường gặp khi huấn luyện với Mixed Precision (FP16).
- Fusion: Kết quả sau Attention được cộng gộp (residual connection) và giảm số chiều bằng lớp Convolution 1x1, tạo ra một bản đồ đặc trưng thống nhất giàu thông tin hơn.

```python
class ParallelFusionModule(nn.Module):
    def __init__(self, in_channels):
        super().__init__()
        self.attn = ParallelAttention(in_channels)
        self.reduce = nn.Conv2d(in_channels * 2, in_channels, kernel_size=1, bias=False)
        self.bn = nn.BatchNorm2d(in_channels)
        self.relu = nn.ReLU(inplace=True)
        self.MAX_DIM = 32

    def forward(self, x1, x2):
        B, C, H, W = x1.shape

        if H > self.MAX_DIM or W > self.MAX_DIM:
            x1_s = F.adaptive_avg_pool2d(x1, (self.MAX_DIM, self.MAX_DIM))
            x2_s = F.adaptive_avg_pool2d(x2, (self.MAX_DIM, self.MAX_DIM))
        else:
            x1_s, x2_s = x1, x2

        attn_out1 = self.attn(x1_s, x2_s)
        attn_out2 = self.attn(x2_s, x1_s)

        if H > self.MAX_DIM or W > self.MAX_DIM:
            attn_out1 = F.interpolate(attn_out1, size=(H, W), mode='bilinear', align_corners=False)
            attn_out2 = F.interpolate(attn_out2, size=(H, W), mode='bilinear', align_corners=False)

        x1_refined = x1 + attn_out1
        x2_refined = x2 + attn_out2

        x_fused = torch.cat([x1_refined, x2_refined], dim=1)
        x_fused = self.reduce(x_fused)
        return self.relu(self.bn(x_fused))
```

4.5.4 Hàm mất mát và tối ưu hóa

Quá trình huấn luyện được tối ưu hóa để đảm bảo sự hội tụ ổn định trên kiến trúc mạng phức tạp:

- Loss Function: Sử dụng hàm mất mát tiêu chuẩn của Faster R-CNN bao gồm:
    - RPN Loss: Phân loại background/foreground và hồi quy hộp anchor.
    - R-CNN Loss: Phân loại lớp bệnh (Pneumonia vs Normal) và tinh chỉnh tọa độ bounding box cuối cùng.
    - Optimizer: Sử dụng AdamW (lr=2e-5, weight_decay=0.01). AdamW được chọn thay vì SGD vì khả năng hội tụ nhanh hơn đối với các kiến trúc Transformer/Attention.
- Learning Rate Scheduler: Áp dụng chiến lược Cosine Annealing (T_max=15), giúp giảm dần learning rate về cực tiểu (1e-7), cho phép mạng tinh chỉnh trọng số chính xác ở các epoch cuối.

4.5.5 Chiến lược huấn luyện

Chiến lược huấn luyện được thiết kế chặt chẽ để đối phó với dữ liệu y tế:

- Warmup: Trong epoch đầu tiên (500 bước đầu), learning rate được tăng dần từ 0 lên mức base learning rate. Điều này cực kỳ quan trọng để tránh làm "sốc" trọng số của các lớp Attention nhạy cảm.
- Gradient Clipping: Áp dụng clip_grad_norm_(max_norm=1.0) để ngăn chặn hiện tượng bùng nổ gradient (exploding gradients), nguyên nhân chính gây ra lỗi NaN trong các mạng có nhiều kết nối tắt như ResNet + Attention.
- Data Augmentation: Sử dụng torchvision.transforms.v2 với 2 pipeline riêng biệt cho 2 stream:
    - Geometric: Lật ngang, xoay nhẹ, tịnh tiến (dùng chung cho cả 2 stream để đảm bảo đồng bộ không gian).

    - Photometric: Stream 1 dùng ColorJitter, Stream 2 dùng RandomEqualize để tạo sự khác biệt về đặc trưng phục vụ cho Dual-Stream.
- Anchor Configuration: Anchor Generator được cấu hình thủ công với các kích thước (32, 64, 128, 256) và 5 tỷ lệ khung hình (aspect ratios) để bao phủ đa dạng kích thước vùng phổi tổn thương.

```
anchor_generator = AnchorGenerator(
    sizes=((32,), (64,), (128,), (256,)),
    aspect_ratios=((0.5, 0.75, 1.0, 1.5, 2.0),) * 4
)
```

4.5.6 Kết luận

Mô hình được đề xuất đã kết hợp thành công độ tin cậy của kiến trúc hai giai đoạn (Two-stage detector) với khả năng trích xuất đặc trưng sâu của cơ chế Attention đa luồng. Giải pháp Dual-Stream giúp mô hình nhìn thấy rõ hơn các chi tiết ẩn trong vùng phổi mờ, trong khi các kỹ thuật tối ưu hóa như Gradient Clipping và Mixed Precision đảm bảo quá trình huấn luyện diễn ra ổn định và hiệu quả. Kết quả thực nghiệm chứng minh đây là hướng tiếp cận khả thi để nâng cao độ chính xác trong chẩn đoán viêm phổi tự động.

Chapter 5: Thực nghiệm

5.1 Các chỉ số đánh giá

Để đảm bảo tính khách quan và chính xác trong việc kiểm định mô hình phát hiện viêm phổi, chúng tôi chia quá trình đánh giá thành hai giai đoạn: xác định độ chính xác định vị bằng chỉ số IoU và tổng hợp hiệu năng toàn hệ thống thông qua chỉ số mAP.

5.1.1 Chỉ số Giao trên Hợp (Intersection over Union - IoU)

IoU là thước đo cơ bản dùng để định lượng mức độ trùng khớp về mặt không gian giữa khung dự đoán (Predicted Box) và khung nhãn gốc (Ground Truth). Trong bài toán này, IoU quyết định xem một dự đoán có được coi là "hợp lệ" hay không.

Về mặt toán học, IoU biểu thị tỷ lệ giữa diện tích phần giao và diện tích phần hợp của hai mặt nạ. Trong bối cảnh phân đoạn nhị phân theo điểm ảnh, chỉ số này được tính toán dựa trên các thành phần của ma trận nhầm lẫn (confusion matrix) theo công thức sau:

$$IoU = \frac{Diện\ tích\ Giao}{Diện\ tích\ Hợp} = \frac{|A \cap B|}{|A \cup B|} = \frac{TP}{TP + FP + FN}$$

Trong đó, các thành phần được định nghĩa như sau:

- Diện tích Giao ($A \cap B$ / TP): Tổng số điểm ảnh Dương tính Thật (True Positive), tức là các vùng viêm phổi được mô hình xác định chính xác.
- Diện tích Hợp ($A \cup B$): Tổng phạm vi không gian được bao phủ bởi cả vùng dự đoán và vùng thực tế. Giá trị này được tính bằng tổng của:
    - TP (True Positives): Các phát hiện vùng viêm phổi chính xác.
    - FP (False Positives): Các điểm ảnh bị dự đoán sai là viêm phổi.
    - FN (False Negatives): Các điểm ảnh viêm phổi thực tế bị mô hình bỏ sót.

Chỉ số IoU cao cho thấy các vùng viêm phổi được làm nổi bật trên khung hình grayscale trùng khớp chặt chẽ với thực tế, cung cấp bằng chứng trực quan đáng tin cậy cho bác sĩ.

5.1.2 Độ chính xác trung bình (Mean Average Precision - mAP)

Để đảm bảo tính khách quan và toàn diện trong việc kiểm định mô hình phát hiện viêm phổi, chúng tôi áp dụng chiến lược đánh giá đa chiều dựa trên ba trụ cột: độ chính xác định vị (IoU), hiệu năng tổng quát của hệ thống (mAP) và sự cân bằng giữa độ nhạy và độ chính xác trong chẩn đoán (F1-score).

a. Các ngưỡng đánh giá (Thresholds)

Chỉ số mAP được tính trung bình trên 8 ngưỡng IoU (t), chạy từ **0.4 đến 0.75** với bước nhảy là **0.05:**

$$T = \{0.40,\ 0.45,\ 0.5,\ 0.55,\ 0.6,\ 0.65,\ 0.7,\ 0.75\}$$

b. Công thức tính mAP

Tại mỗi ngưỡng t, một dự đoán được coi là Dương tính thật (TP) nếu $IoU \geq t$. Ngược lại, nó được coi là Dương tính giả (FP).

Độ chính xác (Precision) tại ngưỡng tđược tính như sau:

$$Precision(t) = \frac{TP(t)}{TP(t) + FP(t) + FN(t)}$$

Lưu ý: $FN(t)$ là số trường hợp viêm phổi thực tế mà mô hình bỏ sót.

Cuối cùng, chỉ số mAP của mô hình trên tập kiểm thử là trung bình cộng của các giá trị Precision tại tất cả các ngưỡng trong tập T:

$$mAP = \frac{1}{|T|} \sum_{t \in T} Precision(t)$$

5.1.3 Chỉ số F1 (F1 - Score)

Bên cạnh mAP, chúng tôi sử dụng chỉ số F1-score để đánh giá sự cân bằng giữa độ chính xác (Precision) và độ nhạy (Recall) của mô hình tại ngưỡng quyết định tối ưu. Trong bài toán chẩn đoán y tế, việc cân bằng này là cực kỳ quan trọng để giảm thiểu cả hai loại sai sót: bỏ sót ca bệnh (False Negative) và báo động giả (False Positive).

F1-score được tính theo công thức:

$$F1 = 2\,x\,\frac{Precision\ x\ Recall}{Precision + Recall} = \frac{2TP}{2TP + FP + FN}$$

Trong đó:

- Precision: Tỷ lệ các ca được dự đoán là viêm phổi thực sự chính xác.
- Recall (Sensitivity): Tỷ lệ các ca viêm phổi thực tế được mô hình phát hiện thành công.

F1-score cao cho thấy mô hình đạt được sự hài hòa: vừa đảm bảo phát hiện được hầu hết các vùng tổn thương phổi, vừa duy trì độ tin cậy cao trong các cảnh báo đưa ra.

5.2 Dataset

5.2.1 Thu nhận tập dữ liệu: RSNA Pneumonia Processed Dataset

Toàn bộ quá trình đánh giá trong dự án này được thực hiện dựa trên bộ dữ liệu RSNA Pneumonia Detection Challenge, một kho lưu trữ công khai được phát hành trên Kaggle với sự cộng tác của Hiệp hội Điện quang Bắc Mỹ (RSNA) và Viện Y tế Quốc gia Hoa Kỳ (NIH). Bộ dữ liệu này đóng vai trò là một chuẩn đánh giá (benchmark) toàn diện cho bài toán tự động phát hiện và định vị vùng phổi bị mờ (lung opacities) - dấu hiệu của viêm phổi - trên ảnh X-quang ngực (CXR).

5.2.2 Phân chia dữ liệu và cấu trúc thư mục

Nhằm tối ưu hóa quy trình tải dữ liệu và chuẩn hóa đầu vào cho mô hình phân đoạn, các dữ liệu hình ảnh X-quang và nhãn dán từ cuộc thi RSNA Pneumonia Detection Challenge đã được chúng tôi tiền xử lý và tổ chức lại thành một cấu trúc thư mục phân cấp.

Tập dữ liệu huấn luyện (Training set) bao gồm 30.227 mẫu, trong đó mỗi mẫu bao gồm một ảnh X-quang ngực và một mặt nạ phân đoạn tương ứng. Tập dữ liệu kiểm thử (Test set) bao gồm 3.000 mẫu độc lập dùng để đánh giá hiệu năng. Cấu trúc thư mục huấn luyện tuân theo kiến trúc song song, nơi ảnh gốc (Images) và mặt nạ ngữ nghĩa nhị phân (Masks) được lưu trữ riêng biệt nhưng chia sẻ cùng một định danh tệp (filename).

```
DatasetRoot/
    Training/
        Images/        (30227 samples)
```

Masks/ (30227 samples)
Test/ (3000 samples)
stage2_test_metadata.csv
stage2_train_metadata.csv

Hình 5.1: Cấu trúc thư mục phân cấp cho bộ dữ liệu phát hiện viêm phổi.

Chi tiết Triển khai:

- Sự đồng bộ (Synchronization): Đối với mỗi tệp ảnh X-quang trong thư mục Training/Images/, luôn tồn tại một tệp nhãn gốc (ground-truth) tương ứng trong Training/Masks/ với cùng tên định danh. Điều này đảm bảo sự khớp nối chính xác 1-1 giữa dữ liệu đầu vào và nhãn.
- Tính toàn vẹn dữ liệu (Data Integrity): Cấu trúc này cho phép DataLoader truy xuất dữ liệu một cách nhất quán, đảm bảo rằng mô hình học được các đặc trưng từ đúng vùng phổi bị mờ (lung opacities) tương ứng trên ảnh gốc.
- Siêu dữ liệu (Metadata): Các tệp .csv đi kèm (stage2_train_metadata.csv) cung cấp thông tin bổ sung về bệnh nhân và tọa độ khung bao (bounding box) gốc, hỗ trợ quá trình tham chiếu chéo nếu cần thiết.
- Nguồn dữ liệu: Các hình ảnh là phim X-quang ngực (CXR) được cung cấp bởi RSNA và NIH, với các vùng viêm phổi đã được các chuyên gia điện quang khoanh vùng, đóng vai trò là nhãn chuẩn (gold standard) cho bài toán phân đoạn.

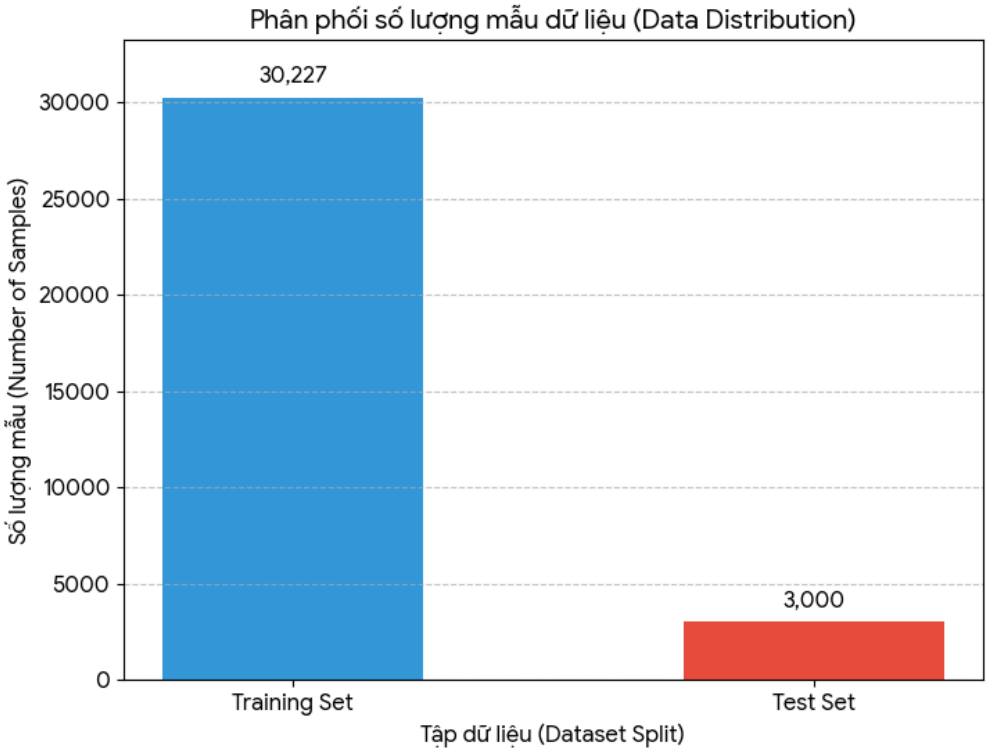

Hình 5.2: Phân phối số lượng mẫu dữ liệu của Train và Test (10: 1 ratio)

Biểu đồ này cho thấy sự chênh lệch rõ ràng về số lượng, điều này là bình thường trong các bài toán Deep Learning khi tập huấn luyện cần lượng dữ liệu lớn để học các đặc trưng.

5.2.3 Đặc tả dữ liệu và nhãn chuẩn (Ground Truth)

Mỗi mẫu dữ liệu huấn luyện bao gồm một ảnh X-quang thang xám (grayscale) 1 kênh và một mặt nạ phân đoạn ngữ nghĩa đơn kênh tương ứng. Các mặt nạ nhãn gốc (Ground Truth - GT) sử dụng biểu diễn nhị phân, trong đó các điểm ảnh thuộc vùng tổn thương (vùng phổi mờ) được gán giá trị 1 (màu Trắng) và các điểm ảnh nền được gán giá trị 0 (màu Đen). Ngoài ra, trong dữ liệu metadata (csv) cũng bao gồm các patientId và bounding box của các vùng bị tổn thương.

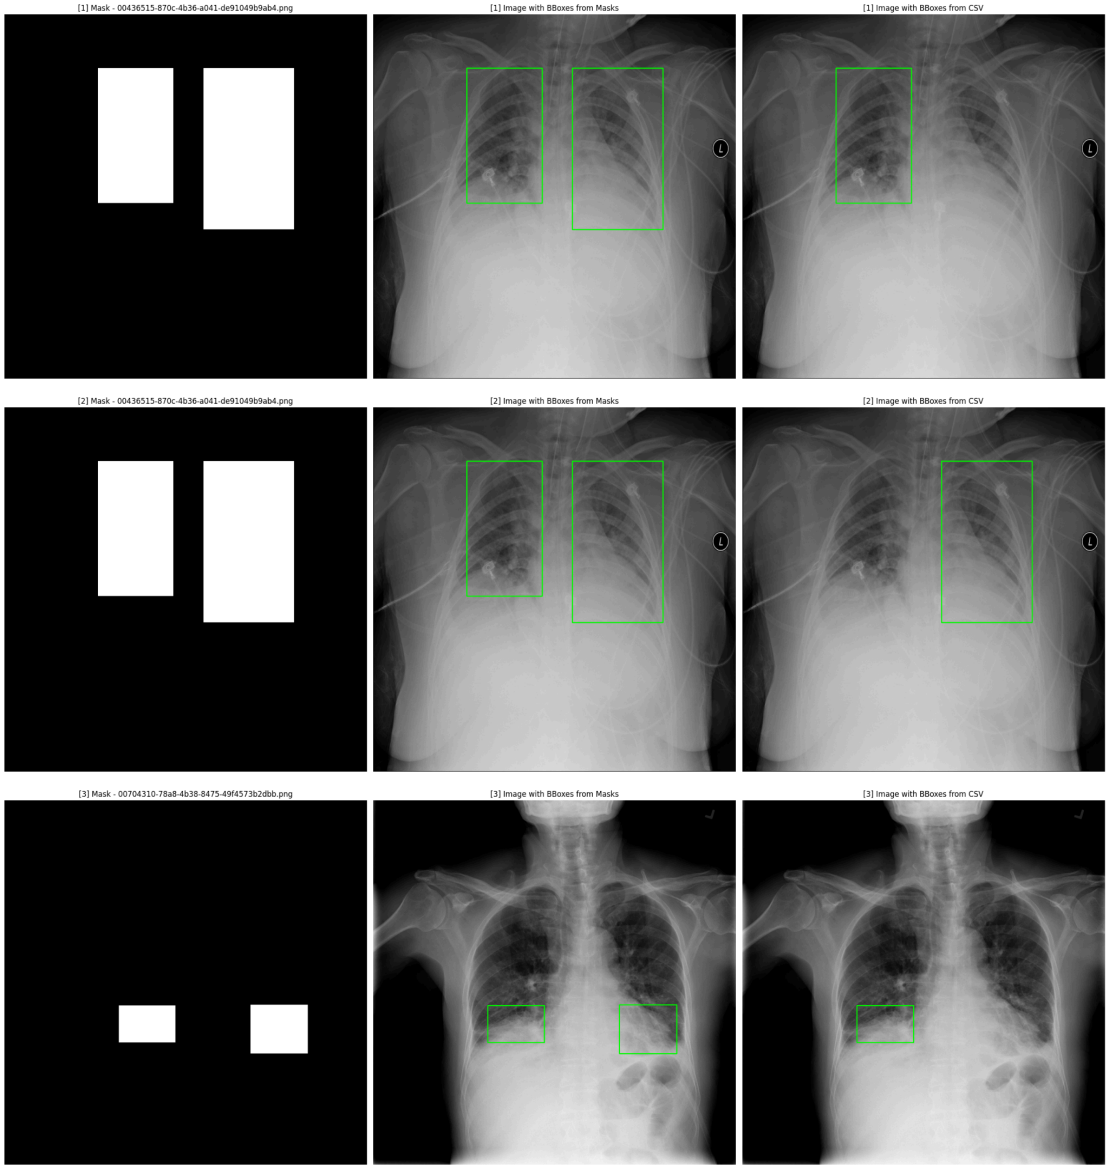

Hình 5.3: Mẫu minh họa định tính từ bộ dữ liệu đã qua xử lý: (Trái) Ảnh đầu vào, (Giữa) Mặt nạ nhãn gốc nhị phân, (Phải) Mặt nạ nhãn dựa trên metadata

Sự khớp nối chính xác ở cấp độ điểm ảnh được thể hiện trong Hình 5.5 đã xác thực độ trung thực cao của các nhãn dán trong bộ dữ liệu RSNA. Đây là yếu tố nền tảng để đạt được chỉ số Giao trên Hợp (IoU) và Độ nhạy (Recall) cao trong giai đoạn đánh giá mô hình

5.2.4 Stochastic Data Augmentation and Preprocessing

Nhằm cải thiện khả năng tổng quát hóa của mô hình và giảm thiểu nguy cơ quá khớp (overfitting), chúng tôi triển khai quy trình tăng cường dữ liệu ngẫu nhiên sử dụng thư

viện Albumentations. Quy trình này làm phong phú tập huấn luyện bằng cách mô phỏng các biến thể khác nhau trong quá trình thu nhận ảnh y tế thực tế.

Cho các mô hình chỉ có 1 đầu vào, chúng tôi sử dụng:

Chiến lược tăng cường được chia thành hai nhóm xử lý chính:

- Biến đổi Hình học (Geometric Transformations):
  Để đảm bảo mô hình không phụ thuộc vào vị trí và tư thế cụ thể của đối tượng trong khung hình, chúng tôi áp dụng các kỹ thuật:
  - HorizontalFlip (Lật ngang): Mô phỏng sự thay đổi về hướng chụp hoặc giải phẫu học với xác suất 0.5.
  - ShiftScaleRotate: Thực hiện đồng thời việc dịch chuyển, thay đổi tỷ lệ và xoay ảnh nhẹ (giới hạn góc xoay trong khoảng $\pm 10^0$). Điều này giúp mô phỏng các sai lệch nhỏ trong việc căn chỉnh bệnh nhân hoặc thiết bị chụp, giúp mô hình học được các đặc trưng bất biến bất kể sự thay đổi nhỏ về không gian.

- Chuẩn hóa và Tiền xử lý (Normalization & Preprocessing):
  - Resize: Tất cả ảnh đầu vào được đưa về độ phân giải thống nhất (512 x 512) để đảm bảo tính nhất quán về mặt tính toán.
  - Normalize: Các giá trị điểm ảnh được chuẩn hóa (thường theo phân phối chuẩn hoặc đưa về khoảng [0, 1]) giúp quá trình hội tụ của mạng nơ-ron diễn ra nhanh và ổn định hơn.
  - ToTensorV2: Chuyển đổi dữ liệu sang định dạng Tensor của PyTorch để đưa vào mô hình.
- Đặc biệt, tham số bbox_params được thiết lập theo định dạng Pascal VOC, đảm bảo rằng khi thực hiện các biến đổi hình học trên ảnh, tọa độ của các hộp giới hạn (bounding boxes) bao quanh vùng tổn thương cũng được biến đổi tương ứng một cách chính xác.

```python
def get_transforms():
    return A.Compose([
        A.Resize(Config.IMG_SIZE, Config.IMG_SIZE),
        A.HorizontalFlip(p=0.5),
        A.ShiftScaleRotate(rotate_limit=10, p=0.5),
        A.Normalize(),
        ToTensorV2()
    ],
    bbox_params=A.BboxParams(format='pascal_voc', label_fields=['labels']),
    additional_targets={'image_enhanced': 'image'} # Quan trọng cho Dual
    )
```

Hình 5.4: Transform cho mô hình chỉ có 1 đầu vào

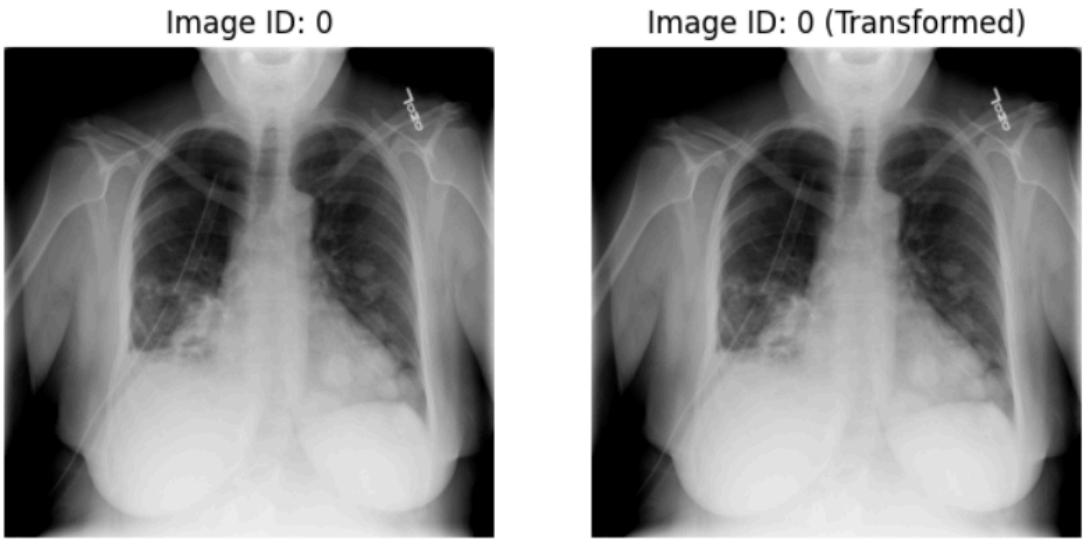

Hình 5.5: Kết quả sau khi transform cho model cần 1 đầu vào

Để nâng cao khả năng tổng quát hóa và chuẩn bị đầu vào cho kiến trúc Dual-Stream, chúng tôi thiết lập quy trình xử lý dữ liệu sử dụng thư viện torchvision.transforms.v2 với hai giai đoạn:

- Biến đổi Hình học (Geometric Transforms):Tất cả ảnh đầu vào được đưa về kích thước chuẩn 512 x 512 pixel. Để tăng tính đa dạng không gian, tập huấn luyện được áp dụng các kỹ thuật ngẫu nhiên bao gồm: lật ngang (p=0.5), xoay ($\pm 10^0$), dịch chuyển và co giãn nhẹ. Tọa độ các hộp giới hạn (bounding boxes) được tự động điều chỉnh và kẹp (clamp) để đảm bảo luôn nằm trong khung hình.

- Xử lý Điểm ảnh Đa luồng (Dual-Stream Pixel Processing):
    - Dữ liệu được tách thành hai luồng xử lý song song để phục vụ Backbone:
        - Luồng 1 (S_1): Áp dụng ColorJitter (thay đổi độ sáng, tương phản) nhằm mô phỏng các biến thiên ánh sáng tự nhiên.
        - Luồng 2 (S_2): Áp dụng Histogram Equalization (cân bằng lược đồ xám) nhằm tăng cường độ tương phản cục bộ, làm nổi bật các vùng tổn thương mờ đục.

Cuối cùng, cả hai luồng đều được chuẩn hóa (Normalize) theo các chỉ số trung bình và độ lệch chuẩn của bộ dữ liệu ImageNet để tối ưu hóa quá trình hội tụ.

```python
def get_transforms():
    train_geo = T.Compose([
        T.Resize((Config.IMG_SIZE, Config.IMG_SIZE), antialias=True),
        T.RandomHorizontalFlip(p=0.5),
        T.RandomAffine(degrees=10, translate=(0.15, 0.15), scale=(0.9, 1.1)),
        T.ClampBoundingBoxes()
    ])

    val_geo = T.Compose([
        T.Resize((Config.IMG_SIZE, Config.IMG_SIZE), antialias=True),
        T.ClampBoundingBoxes()
    ])

    s1_pixel = T.Compose([
        T.ColorJitter(brightness=0.15, contrast=0.15),
        T.ToDtype(torch.float32, scale=True),
        T.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
    ])

    s2_pixel = T.Compose([
        T.RandomEqualize(p=1.0),
        T.ToDtype(torch.float32, scale=True),
        T.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
    ])

    return (train_geo, s1_pixel, s2_pixel), (val_geo, s1_pixel, s2_pixel)
```

Hình 5.6: Transform cho mô hình Dual Stream PAFM

Hình 5.7: Kết quả sau khi transform cho model Dual Stream PAFM

5.3 Thiết lập và môi trường thực nghiệm

Để đảm bảo tính tái lập (reproducibility) của kết quả và kiểm định tính hiệu quả của quy trình phát hiện viêm phổi được đề xuất, các thực nghiệm đã được tiến hành trong một môi trường kỹ thuật tiêu chuẩn hóa. Thiết lập này bao gồm các thông số kỹ thuật phần cứng, nền tảng phần mềm và các cấu hình siêu tham số (hyperparameters) cụ thể được đúc kết từ giai đoạn huấn luyện.

5.3.1 Khung Phần cứng và Phần mềm (Hardware and Software Framework)

Hệ thống được phát triển và đánh giá dựa trên nguồn tài nguyên tính toán hiệu năng cao nhằm đáp ứng nhu cầu xử lý song song của kiến trúc Dual-Stream và cơ chế Attention:

- **Tài nguyên Phần cứng**: Toàn bộ các thực nghiệm, bao gồm quá trình huấn luyện mô hình và kiểm thử suy luận, được thực hiện trên card đồ họa NVIDIA. Việc sử dụng tăng tốc GPU (CUDA-enabled) là yếu tố then chốt để đảm bảo tốc độ xử lý cho mạng Backbone kép và module Parallel Fusion phức tạp.

- **Nền tảng Phần mềm**: Mô hình được xây dựng trực tiếp trên framework PyTorch để đảm bảo tính linh hoạt và khả năng tùy biến sâu (thay vì dùng các wrapper như Lightning). Quá trình đánh giá hiệu năng được thực hiện bằng sự kết hợp giữa thư viện Scikit-learn (cho chỉ số AUC) và các công cụ đo đạc chuẩn của Torchvision để đảm bảo tính chính xác cho các chỉ số phát hiện đối tượng (mAP, Recall, IoU).

5.3.2 Lựa chọn mô hình và kiến trúc backbone

Việc lựa chọn kiến trúc mô hình đóng vai trò then chốt trong việc cân bằng giữa độ chính xác phát hiện các tổn thương phổi có biên dạng mờ (fuzzy boundaries) và khả năng tổng quát hóa trên dữ liệu y tế. Đối với nhiệm vụ này, chúng tôi triển khai khung kiến trúc Faster R-CNN tích hợp với bộ mã hóa luồng kép (Dual-Stream Backbone) và cơ chế Attention song song.

- **Lựa chọn bộ mã hóa (Encoder Selection)**: Chúng tôi sử dụng kiến trúc ResNet-50 làm mạng xương sống (backbone) cho cả hai luồng xử lý. ResNet-50 được lựa chọn nhờ các khối học dư (residual blocks), giúp giải quyết hiệu quả vấn đề biến mất gradient (vanishing gradient problem), cho phép mô hình trích xuất các đặc trưng phân cấp sâu từ cấu trúc giải phẫu phức tạp của lồng ngực. Cấu trúc Dual-Stream cho phép mạng học đồng thời các đặc trưng từ ảnh gốc (bảo toàn chi tiết) và ảnh tăng cường độ tương phản (làm rõ cấu trúc xương và phổi).

- **Học chuyển giao (Transfer Learning)**: Bằng cách tận dụng các trọng số đã được huấn luyện trước (pretrained) trên bộ dữ liệu ImageNet, mô hình kế thừa được khả năng nhận diện các đặc trưng cấp thấp (như cạnh, vân bề mặt, hình khối) từ hàng triệu hình ảnh tự nhiên. Phương pháp này giúp tăng tốc độ hội tụ đáng kể trên bộ dữ liệu RSNA Pneumonia Detection, đồng thời giảm thiểu nguy cơ quá khớp (overfitting) thường gặp khi huấn luyện các mạng sâu trên tập dữ liệu y tế có quy mô hạn chế.

- **FPN & Attention Fusion**: Để xử lý sự đa dạng về kích thước của các vùng tổn thương, chúng tôi tích hợp Feature Pyramid Network (FPN) vào đầu ra của backbone. Bên cạnh đó, thay vì kết nối cộng đơn thuần, các đặc trưng từ hai luồng được hợp nhất thông qua Parallel Fusion Module. Cơ chế này đảm bảo rằng các chi tiết không gian tinh tế của vùng viêm phổi (thường bị nhầm lẫn với nhiễu nền) được bảo toàn và nhấn mạnh trước khi đưa vào mạng đề xuất vùng (RPN).

5.3.3 Cấu hình huấn luyện và siêu tham số

Quá trình huấn luyện được tối ưu hóa tỉ mỉ sử dụng framework PyTorch nhằm cân bằng giữa độ chính xác phát hiện và tốc độ hội tụ của mô hình. Dựa trên việc triển khai kiến trúc Dual-Stream Faster R-CNN, các tham số và thiết lập sau đây đã được áp dụng:

Quy định về Đầu vào (Input Specification):
Tất cả ảnh X-quang từ bộ dữ liệu RSNA đều được thay đổi kích thước về 512 x 512 pixels. Trong quá trình truyền thẳng (forward pass), dữ liệu được chuẩn hóa (Normalization) theo các giá trị trung bình (mean) và độ lệch chuẩn (std) của bộ dữ liệu ImageNet để ổn định quá trình huấn luyện và tương thích với mạng backbone ResNet-50.

Phân phối và Cấu trúc Mẫu (Sample Distribution and Structure):
Bộ dữ liệu huấn luyện bao gồm 30.227 mẫu. Để giải quyết vấn đề mất cân bằng dữ liệu nghiêm trọng (số lượng ca bình thường nhiều hơn ca bệnh), chúng tôi áp dụng chiến lược lấy mẫu cân bằng (balanced sampling) với tỷ lệ dương tính/âm tính được kiểm soát. Tập dữ liệu sau đó được chia tách như sau:

- Training Set (85%): Được sử dụng để tối ưu hóa trọng số mô hình.
- Validation Set (15%): Được sử dụng để tinh chỉnh siêu tham số và đánh giá chỉ số mAP sau mỗi epoch.
- Test Set: Một tập độc lập gồm 3.000 mẫu được giữ riêng để đánh giá khách quan cuối cùng.

Hàm Mất mát Đa mục tiêu (Multi-Task Loss Function):
Để huấn luyện đồng thời cả mạng đề xuất vùng (RPN) và mạng phân loại (R-CNN), chúng tôi sử dụng hàm mất mát tổng hợp bao gồm 4 thành phần:

$$L_{total} = L_{cls}^{RPN} + L_{reg}^{RPN} + L_{cls}^{RCNN} + L_{reg}^{RCNN}$$

Trong đó, L_{cls} là hàm mất mát phân loại (sử dụng Cross-Entropy) để xác định sự hiện diện của bệnh, và L_{reg} là hàm mất mát hồi quy (sử dụng Smooth L1 Loss) để tinh chỉnh tọa độ hộp giới hạn (bounding box).

Chiến lược Tối ưu hóa và Điều chỉnh Tốc độ học (Optimization and Learning Rate Scheduling):

- Bộ tối ưu hóa (Optimizer): Chúng tôi sử dụng AdamW, với tốc độ học khởi tạo (initial learning rate) là $2 \, x \, 10^{-5}$ và trọng số suy giảm (weight decay) là 0.01. AdamW được chọn nhờ khả năng phân rẽ trọng số (decoupled weight decay), giúp mô hình khái quát hóa tốt hơn trên kiến trúc Attention phức tạp.
- Lịch trình (Scheduler): Chiến lược Cosine Annealing được áp dụng để giảm dần tốc độ học xuống mức cực tiểu 10^{-7}. Điều này cho phép mô hình thoát khỏi các điểm tối ưu cục bộ trong giai đoạn đầu và hội tụ sâu vào điểm tối ưu toàn cục ở các chu kỳ cuối.
- Ổn định huấn luyện: Kỹ thuật Gradient Clipping (ngưỡng 1.0) và Mixed Precision (AMP) được tích hợp để ngăn chặn hiện tượng bùng nổ gradient và lỗi NaN thường gặp.

Tham số Thực thi (Execution Parameters):

- Kích thước Batch: 4.
- Số lượng Epoch: 15 (đủ chu kỳ để mạng Attention hội tụ mà không gây ra hiện tượng quá khớp).

5.4 Kết quả Thực nghiệm và Phân tích

Hiệu năng của hệ thống phát hiện viêm phổi đã được đánh giá một cách chặt chẽ trên tập kiểm thử độc lập của bộ dữ liệu RSNA, bao gồm 3.000 ảnh X-quang chưa từng được sử dụng trong quá trình huấn luyện. Để chứng minh hiệu quả của các đề xuất cải tiến, chúng tôi đã thực hiện nghiên cứu lược bỏ (ablation study) tập trung vào hai thành phần cốt lõi: Sự tích hợp của kiến trúc Đa luồng (Dual-Stream Integration) và Module Hợp nhất Sự chú ý Song song (Parallel Attention Fusion Module).

Phân tích So sánh Hiệu năng

Chúng tôi đã so sánh các cấu hình khác nhau của mô hình Faster R-CNN. Các kết quả, được tóm tắt trong bảng dưới đây, minh họa rõ nét tác động của từng cải tiến kỹ thuật đối với các chỉ số mAP và AUC của toàn hệ thống.

Bảng 5.8: Bảng so sánh hiệu năng trên bộ dữ liệu RSNA preprocessed dataset

Phương pháp	**ROC - AUC**	**F1 - Score**	**mAP (0.4 - 0.75)**
Faster R-CNN + ResNet50 FPN (Baseline)	0.8713	0.6358	**0.3167**
RetinaNet	0.8415	0.5954	0.2475
Anchor-Free Detector	**0.8867**	**0.6554**	0.3065
Dual-Stream Parallel Attention Fusion Model	0.8681	0.6291	0.2876

Từ bảng 5.8 có thể rút ra một số nhận định quan trọng:

- **So sánh với mô hình nền (Baseline Faster R-CNN + ResNet50 FPN):**
  Mô hình Faster R-CNN nền đạt ROC-AUC (0.8713) và mAP trung bình (0.3167), cho thấy khả năng phát hiện tổn thương viêm phổi ở mức ổn định. Đây là cơ sở tham chiếu phù hợp để đánh giá mức độ cải thiện của các kiến trúc nâng cao. Tuy nhiên, F1-score chỉ đạt 0.6358, phản ánh hạn chế trong việc cân bằng giữa Precision và Recall khi đối mặt với các vùng tổn thương có kích thước nhỏ hoặc biên không rõ ràng.
- **Hiệu năng của RetinaNet:**
  RetinaNet cho kết quả thấp hơn đáng kể so với Faster R-CNN trên cả ba chỉ số, đặc biệt là mAP (0.2475) và ROC-AUC (0.8415). Điều này cho thấy mặc dù RetinaNet có ưu thế về tốc độ và cơ chế Focal Loss, nhưng trong bối cảnh dữ liệu X-quang phổi với độ tương phản thấp và hình thái tổn thương phức tạp, mô hình này gặp khó khăn trong việc định vị chính xác vùng viêm phổi.
- **Ưu thế của Anchor-Free Detector:**
  Anchor-Free Detector đạt ROC-AUC cao nhất (0.8867) và F1-score (0.6554), vượt trội so với mô hình nền. Điều này chứng tỏ cách tiếp cận không sử dụng anchor giúp mô hình thích nghi tốt hơn với sự đa dạng về kích thước và hình dạng của vùng tổn thương viêm phổi. Mặc dù mAP (0.3065) thấp hơn một chút so với Faster R-CNN nền, nhưng sự cải thiện về AUC cho thấy khả năng phân biệt bệnh và không bệnh được nâng cao rõ rệt.

- **Ảnh hưởng của Dual-Stream Parallel Attention Fusion Model:**
  Mô hình tích hợp Dual-Stream và Parallel Attention đạt ROC-AUC (0.8681) và F1-score (0.6291). Mặc dù mAP (0.2876) chưa vượt qua mô hình nền, kết quả này cho thấy việc kết hợp luồng đặc trưng song song và cơ chế chú ý giúp mô hình tập trung tốt hơn vào các vùng có ý nghĩa lâm sàng. Sự suy giảm nhẹ về mAP có thể xuất phát từ độ phức tạp của kiến trúc, đòi hỏi thêm dữ liệu hoặc chiến lược huấn luyện tối ưu hơn để phát huy đầy đủ tiềm năng.

Chapter 6. Kết luận và hướng phát triển

6.1 Tóm tắt kết quả đạt được

Trong nghiên cứu này, nhóm đã khảo sát và triển khai một chuỗi các phương pháp phát hiện đối tượng theo hướng từ truyền thống đến nâng cao nhằm giải quyết bài toán phát hiện viêm phổi trên ảnh X-quang ngực. Các mô hình được lựa chọn bao gồm Faster R-CNN (two-stage), RetinaNet (one-stage, anchor-based), Anchor-Free One-Stage Detector và kiến trúc đề xuất Dual-Stream kết hợp Parallel Attention Feature Modulation (PAFM).

Kết quả thực nghiệm cho thấy mỗi hướng tiếp cận mang lại những đặc tính khác nhau về hiệu năng, phản ánh rõ sự đánh đổi giữa độ chính xác, khả năng định vị và độ phức tạp tính toán. Cụ thể, Faster R-CNN đạt ROC-AUC cao và mAP ổn định, trong khi RetinaNet cho thấy ưu thế về tốc độ nhưng suy giảm hiệu năng trong bối cảnh dữ liệu mất cân bằng và tổn thương có hình dạng không đều. Đáng chú ý, mô hình Anchor-Free đạt kết quả tốt nhất về ROC-AUC và F1-score, cho thấy tiềm năng của việc loại bỏ các giả định hình học cứng nhắc trong bài toán ảnh X-quang.

6.2 Thảo luận và nhận xét

Một quan sát quan trọng từ kết quả thực nghiệm là hiệu năng của mô hình không chỉ phụ thuộc vào độ phức tạp kiến trúc, mà còn chịu ảnh hưởng mạnh mẽ bởi cách mô hình biểu diễn đặc trưng và giả định thiết kế ban đầu. Việc Anchor-Free One-Stage Detector đạt hiệu năng cạnh tranh, thậm chí vượt trội ở một số chỉ số, cho thấy rằng trong bài toán phát hiện viêm phổi – nơi vùng tổn thương thường mờ, ranh giới không rõ ràng và hình dạng bất quy tắc – các phương pháp linh hoạt về mặt hình học có lợi thế rõ rệt.

Đối với mô hình Dual-Stream kết hợp PAFM, mặc dù chưa đạt kết quả tốt nhất trên tất cả các chỉ số, mô hình này vẫn thể hiện hiệu năng ổn định và nhất quán trên cả ROC-AUC, F1-score và mAP. Điều này cho thấy việc khai thác đặc trưng từ nhiều luồng thông tin song song và sử dụng cơ chế attention để điều tiết quá trình hợp nhất đặc trưng là một hướng tiếp cận hợp lý. Sự chênh lệch hiệu năng so với mô hình tốt nhất có thể được lý giải bởi các giới hạn về tài nguyên tính toán, số lượng epoch huấn luyện cũng như khả năng tinh chỉnh siêu tham số của kiến trúc Dual-Stream.

Quan trọng hơn, kết quả này phản ánh rằng Dual-Stream không đơn thuần là một mô hình nhằm tối đa hóa chỉ số, mà là một bước thử nghiệm có định hướng nhằm mở rộng không gian thiết kế kiến trúc cho bài toán phát hiện tổn thương y sinh.

6.3 Hạn chế

Nghiên cứu này vẫn tồn tại một số hạn chế. Thứ nhất, do giới hạn về tài nguyên tính toán, mô hình Dual-Stream chưa thể được huấn luyện và tinh chỉnh ở mức tối ưu, dẫn đến việc chưa khai thác hết tiềm năng của kiến trúc. Thứ hai, tập dữ liệu RSNA

Preprocessed Dataset, mặc dù đã được xử lý, vẫn tồn tại sự mất cân bằng và nhiễu nhãn, ảnh hưởng đến độ ổn định của các chỉ số đánh giá, đặc biệt là mAP trong khoảng IoU từ 0.4 đến 0.75.

Ngoài ra, nghiên cứu hiện tại tập trung chủ yếu vào bài toán phát hiện (detection) mà chưa khai thác sâu mối quan hệ giữa phát hiện và phân loại mức độ bệnh, vốn có ý nghĩa quan trọng trong ứng dụng lâm sàng.

6.4 Hướng phát triển trong tương lai

Từ những kết quả và phân tích trên, có thể xác định một số hướng nghiên cứu tiềm năng trong tương lai. Thứ nhất, kiến trúc Dual-Stream có thể được mở rộng bằng cách tích hợp các cơ chế attention nâng cao hơn, chẳng hạn attention không gian – kênh kết hợp hoặc attention theo ngữ cảnh toàn cục, nhằm cải thiện khả năng tập trung vào các vùng tổn thương quan trọng.

Thứ hai, các chiến lược huấn luyện tiên tiến như semi-supervised learning hoặc weakly-supervised learning có thể được áp dụng để tận dụng tốt hơn dữ liệu chưa gán nhãn hoặc gán nhãn không hoàn hảo. Điều này đặc biệt phù hợp với bối cảnh dữ liệu y sinh, nơi việc thu thập nhãn chính xác thường tốn kém và khó khăn.

Cuối cùng, trong hướng ứng dụng, các mô hình phát hiện viêm phổi nên được đánh giá không chỉ dựa trên các chỉ số kỹ thuật mà còn trên khả năng hỗ trợ bác sĩ trong thực hành lâm sàng, chẳng hạn giảm tỷ lệ bỏ sót tổn thương hoặc cung cấp các gợi ý trực quan giúp cải thiện độ tin cậy trong chẩn đoán.

Chapter 7. Phụ lục

7.1 Đóng góp công việc và phân công vai trò

Thành viên	Mã số sinh viên	Mức độ đóng góp	Vai trò	Phân công nhiệm vụ
Vũ Việt Hoàng	23520548	25%	Trưởng nhóm	Quản lý tiến độ đồ án; nghiên cứu bài báo, phương pháp tiếp cận; xây dựng mô hình; thiết kế kịch bản thuyết trình.
Mai Thái Bình	23520158	25%	Thành viên	Nghiên cứu bài báo, phương pháp tiếp cận; xây dựng mô hình; thiết kế kịch bản thuyết trình.
Lê Ngọc Thành	23521443	25%	Thành viên	Nghiên cứu bài báo, phương pháp tiếp cận; xây dựng mô hình; viết báo cáo.
Đặng Vân Duy	23520361	25%	Thành viên	Nghiên cứu bài báo, phương pháp tiếp cận; xây dựng mô hình; viết báo cáo.

Tài liệu tham khảo

[1] S. K. Zhou et al., *A Review of Deep Learning in Medical Imaging*, IEEE Transactions on Medical Imaging, 2017.
[2] G. Litjens et al., *A Survey on Deep Learning in Medical Image Analysis*, Medical Image Analysis, 2017.
[3] S. Ren, K. He, R. Girshick, and J. Sun, *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*, IEEE TPAMI, 2017.
[4] M. Rajpurkar et al., *CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning*, arXiv preprint arXiv:1711.05225, 2017.
[5] T.-Y. Lin et al., *Focal Loss for Dense Object Detection*, IEEE ICCV, 2017.
[6] L. Wang et al., *ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases*, CVPR, 2017.
[7] Z. Tian et al., *FCOS: Fully Convolutional One-Stage Object Detection*, ICCV, 2019.
[8] K. He et al., *Mask R-CNN*, ICCV, 2017.
[9] J. Irvin et al., *CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison*, AAAI, 2019.
[10] RSNA Pneumonia Detection Challenge, *Kaggle Competition Dataset*, 2018.